

Università di Roma Tor Vergata  
Corso di Laurea triennale in Informatica  
**Sistemi operativi e reti**  
A.A. 2016-17

Pietro Frasca

## Lezione 10


Martedì 15-11-2016

# Blocco critico (stallo)

- In un sistema multiprogrammato, durante l'esecuzione, un processo può richiedere risorse condivise per svolgere la sua attività.
- In un determinato istante, la risorsa richiesta potrebbe essere non disponibile perché già allocata in precedenza a un altro processo. In questo caso il processo richiedente passa nello stato di bloccato.
- La situazione di **stallo (deadlock)** si può verificare tra due o più processi quando ciascuno dei processi possiede almeno una risorsa e ne richiede altre. Il processo richiedente non può ottenere la risorsa poiché la risorsa richiesta è stata già assegnata ad un altro processo che non la rilascia in quanto è in attesa di un'altra risorsa che è già allocata ad un altro processo ancora.

- Un gruppo di processi è in uno stato di deadlock quando ogni processo è in attesa di un evento che può essere causato solo da un altro processo appartenente al gruppo.
- In un normale funzionamento, un processo può utilizzare una risorsa seguendo la seguente sequenza
  - 1. Richiesta.** Il processo richiede la risorsa. Se la richiesta non può essere concessa immediatamente (ad esempio, se la risorsa è utilizzata da un altro processo ), allora il processo richiedente deve attendere finché può acquisire la risorsa.
  - 2. Uso.** Il processo esegue operazioni sulla risorsa
  - 3. Rilascio.** Il processo rilascia la risorsa.

- La richiesta e il rilascio delle risorse possono essere chiamate di sistema. Esempi di chiamate di sistema per la richiesta e il rilascio sono:
  - `open ()` e `close ()` per file e dispositivi;
  - `malloc ()` e `free ()` per la memoria.
- Analogamente, come abbiamo visto , le operazioni di richiesta e di rilascio con i semafori possono essere realizzate mediante le operazioni `wait ()` e `signal ()`.



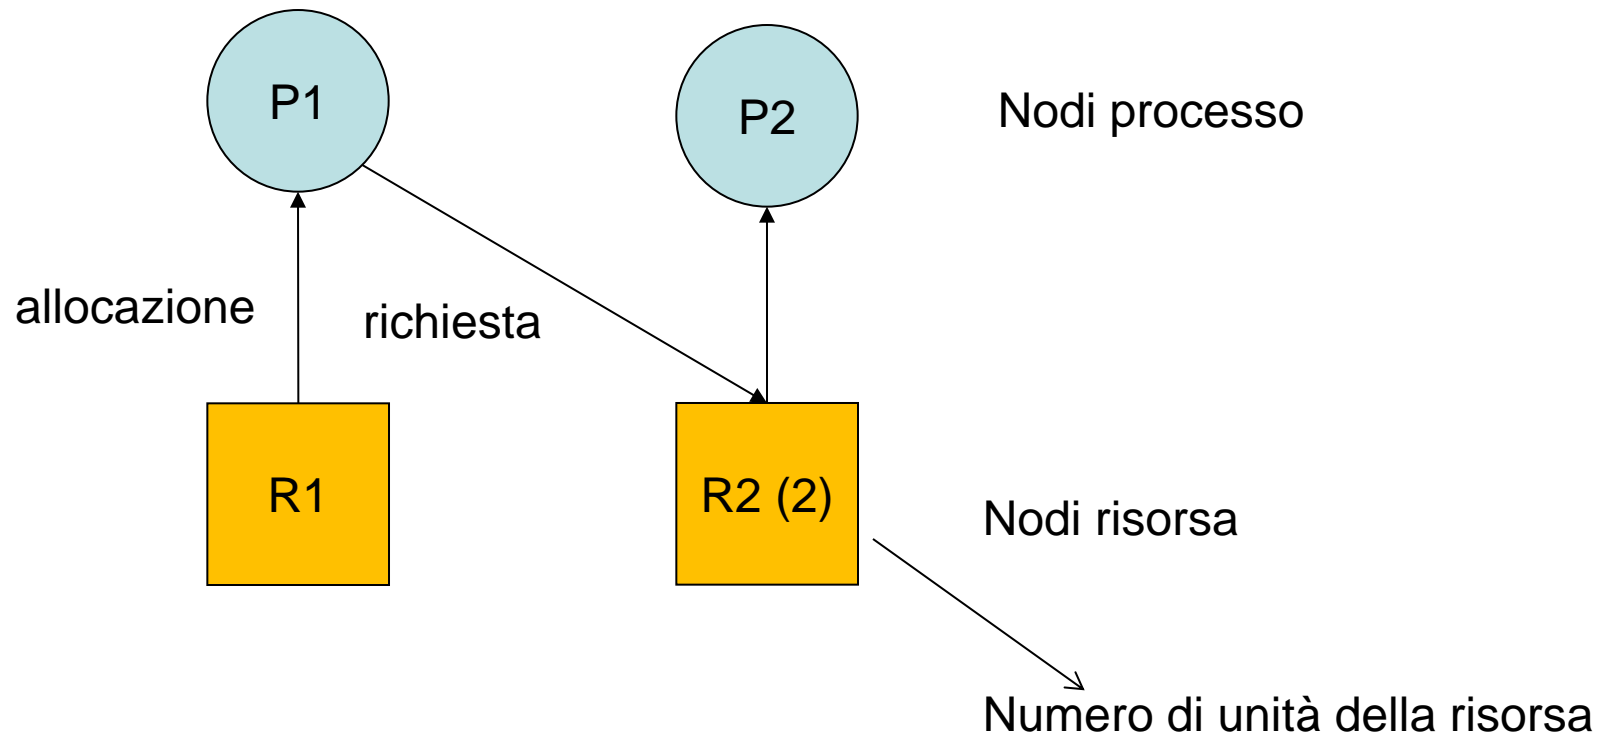
# Rappresentazioni dello stato di allocazione delle risorse

- Per stabilire se un certo numero di processi è in stallo è necessario analizzare le informazioni relative alle risorse allocate ai processi e quelle relative alle richieste di risorse in attesa.
- Per rappresentare lo stato di allocazione di un sistema si utilizzano due tipi di rappresentazione:
  - **Modelli basati su grafo**
  - **Modelli basati su matrici**

## Modelli basati su grafo

- un **grafo di richiesta e allocazione risorse** è costituito da due tipi di nodo: i **nodi processo** e i **nodi risorsa**. Un nodo processo è rappresentato da un cerchio e un nodo risorsa è rappresentato da un quadrato (o da un rettangolo).

- Un numero nel nodo risorsa indica il numero di unità di quel tipo di risorsa.



# Modelli basati su matrici

- Con il modello basato su matrici, lo stato di allocazione del sistema è rappresentato dalle seguenti matrici:

	R1	R2
P1	0	1
P2	1	0
P3	0	1

Risorse allocate

	R1	R2
P1	1	0
P2	0	1
P3	0	0

Risorse richieste

R1	R2
1	2


Risorse totali

R1	R2
0	0

Risorse libere

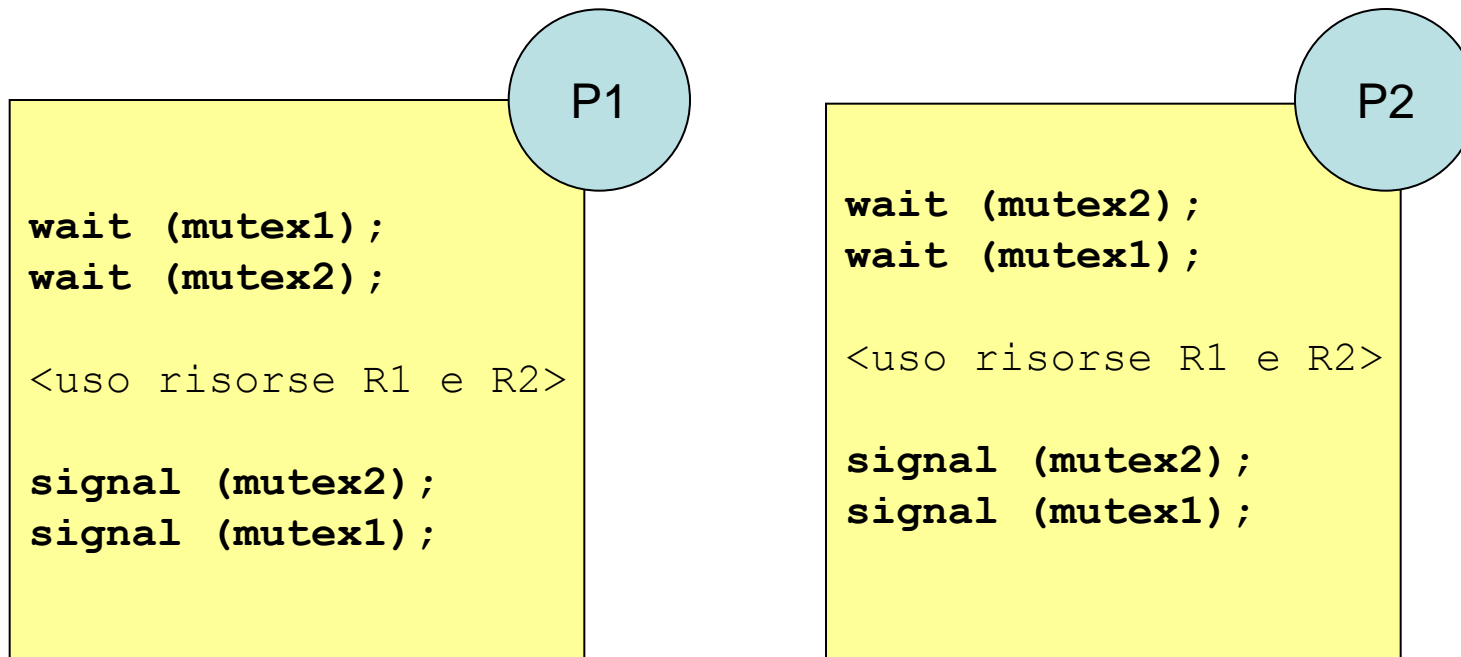
# Esempio di situazione di stallo

- Il seguente grafo di allocazione delle risorse mostra che ciascun processo non può continuare la propria esecuzione in quanto ciascuno è in attesa di una risorsa che è allocata da un altro processo bloccato.







- In certi casi, la situazione di blocco critico dipende dalla ***velocità relativa*** di esecuzione dei processi.
- Consideriamo ad esempio il caso di due processi **P1** e **P2** che richiedono due risorse **R1** e **R2** nell'ordine mostrato nell'esempio seguente.



- Se i due processi P1 e P2 eseguono la seguente sequenza di operazioni nel tempo:  
**T0: P1 esegue wait(mutex1) (acquisisce la risorsa R1)**



- Se i due processi P1 e P2 eseguono la seguente sequenza di operazioni nel tempo:  
T0: P1 esegue wait(mutex1) (acquisisce la risorsa R1)  
**T1: P2 esegue wait(mutex2) (acquisisce la risorsa R2)**




- Se i due processi P1 e P2 eseguono la seguente sequenza di operazioni nel tempo:

T0: P1 esegue wait(mutex1) (acquisisce la risorsa R1)

T1: P2 esegue wait(mutex2) (acquisisce la risorsa R2)

**T2: P1 esegue wait(mutex2) (P1 si blocca)**



- Se i due processi P1 e P2 eseguono la seguente sequenza di operazioni nel tempo:


T0: P1 esegue wait(mutex1) (acquisisce la risorsa R1)

T1: P2 esegue wait(mutex2) (acquisisce la risorsa R2)

T2: P1 esegue wait(mutex2) (P1 si blocca)


**T3: P2 esegue wait(mutex1) (P2 si blocca)**

**i due processi P1 e P2 si bloccano rispettivamente sui semafori mutex2 e mutex1 e non possono uscire dalla situazione di stallo.**



- Quest'altra condizione di velocità relativa non avrebbe portato allo stallo:


**T0: P1 esegue wait(mutex1) (P1 alloca la risorsa R1)**



- Quest'altra condizione di velocità relativa non avrebbe portato allo stallo:

T0: P1 esegue wait(mutex1) (P1 alloca la risorsa R1)

**T1: P1 esegue wait(mutex2) (P1 alloca la risorsa R2)**




- Quest'altra condizione di velocità relativa non avrebbe portato allo stallo:

T0: P1 esegue wait(mutex1) (P1 alloca la risorsa R1)

T1: P1 esegue wait(mutex2) (P1 alloca la risorsa R2)

**T2: P2 esegue wait(mutex2) (P2 si blocca su mutex2)**






- Quest'altra condizione di velocità relativa non avrebbe portato allo stallo:

T0: P1 esegue wait(mutex1) (P1 alloca la risorsa R1)

T1: P1 esegue wait(mutex2) (P1 alloca la risorsa R2)

T2: P2 esegue wait(mutex2) (P2 si blocca su mutex2)

**T3: P1 esegue signal(mutex2) (P1 sblocca il mutex2 e risveglia P2)**



- Quest'altra condizione di velocità relativa non avrebbe portato allo stallo:


T0: P1 esegue wait(mutex1) (P1 alloca la risorsa R1)

T1: P1 esegue wait(mutex2) (P1 alloca la risorsa R2)

T2: P2 esegue wait(mutex2) (P2 si blocca su mutex2)

T3: P1 esegue signal(mutex2) (P1 sblocca il mutex1 e risveglia P2)

**T4: P2 alloca la risorsa R2**



- Quest'altra condizione di velocità relativa non avrebbe portato allo stallo:

T0: P1 esegue wait(mutex1) (P1 alloca la risorsa R1)


T1: P1 esegue wait(mutex2) (P1 alloca la risorsa R2)

T2: P2 esegue wait(mutex2) (P2 si blocca su mutex2)

T3: P1 esegue signal(mutex2) (P1 sblocca il mutex1 e risveglia P2)

T4: P2 alloca la risorsa R2

**T5: P1 esegue signal(mutex1) (P1 rilascia R1)**



- Quest'altra condizione di velocità relativa non avrebbe portato allo stallo:

T0: P1 esegue wait(mutex1) (P1 alloca la risorsa R1)

T1: P1 esegue wait(mutex2) (P1 alloca la risorsa R2)


T2: P2 esegue wait(mutex2) (P2 si blocca su mutex2)

T3: P1 esegue signal(mutex2) (P1 sblocca il mutex1 e risveglia P2)

T4: P2 alloca la risorsa R2

T5: P1 esegue signal(mutex1) (P1 rilascia R1)

**T6: p2 esegue wait(mutex1) (P2 alloca R1)**



- Quest'altra condizione di velocità relativa non avrebbe portato allo stallo:

T1: P1 esegue wait(mutex2) (P1 alloca la risorsa R2)

T2: P2 esegue wait(mutex2) (P2 si blocca su mutex2)


T3: P1 esegue signal(mutex2) (P1 sblocca il mutex1 e risveglia P2)

T4: P2 alloca la risorsa R2

T5: P1 esegue signal(mutex1) (P1 sblocca R1)

T6: P2 esegue wait(mutex1) (P2 alloca R1)

**T7: P2 esegue signal(mutex2) (P2 rilascia R2)**



- Quest'altra condizione di velocità relativa non avrebbe portato allo stallo:

T2: P2 esegue wait(mutex2) (P2 si blocca su mutex2)

T3: P1 esegue signal(mutex2) (P1 sblocca il mutex1 e risveglia P2)


T4: P2 alloca la risorsa R2

T5: P1 esegue signal(mutex1) (P1 rilascia R1)

T6: P2 esegue wait(mutex1) (P2 alloca R1)

T7: P2 esegue signal(mutex2) (P2 rilascia R2)

**T8: P2 esegue signal(mutex1) (P2 rilascia R1)**




## Risorse riusabili, consumabili e condivisibili

- Una risorsa è detta **riusabile** quando può essere usata da un processo alla volta e non viene distrutta dopo l'uso. Esempi di risorse riusabili sono risorse hardware come i dischi, i lettori DVD, le stampanti, scanner, etc. e risorse software come file, tabelle, etc.
- Una risorsa è detta **non riusabile** o **consumabile**, quando non può essere riusata. Esempi di risorse consumabili sono i messaggi, i segnali e le interruzioni. Anche l'utilizzo di tali risorse può portare a situazioni di stallo.
- Una risorsa **è condivisibile** quando è riusabile e può essere usata senza ricorrere alla mutua esclusione. Un esempio di risorsa condivisibile è il file con accesso in sola lettura.

## Blocco critico con risorse consumabili

Consideriamo l'esempio in figura in cui i processi P1 e P2 si comportano rispettivamente da produttore e consumatore rispetto al buffer A e consumatore e produttore rispetto al buffer B. Se **i due buffer sono pieni**, P1 non può inserire il suo messaggio nel buffer A e quindi si blocca in attesa che intervenga P2, il quale a sua volta può essere bloccato in quanto impossibilitato ad inserire il messaggio nel buffer B.






# Condizioni per il blocco critico


- Considerato un insieme di **N** processi  $\{P1, P2..PN\}$  e un insieme di **M** tipi di risorse  $\{R1, R2,..RM\}$  **si può verificare** una condizione di blocco critico se risultano vere **contemporaneamente** tutte le seguenti condizioni:
  1. **Mutua esclusione.** Le risorse possono essere utilizzate da un solo processo alla volta;
  2. **Possesso e attesa.** I processi non rilasciano le risorse che hanno già acquisito e per continuare la loro esecuzione ne richiedono altre;
  3. **Mancanza di pre-rilascio.** Le risorse che sono state già assegnate ai processi non possono essere revocate;
  4. **Attesa circolare.** Esiste un insieme di processi  $\{P_i, P_{i+1}, ..., P_k\}$ , tali che  $P_i$  è in attesa di una risorsa acquisita da  $P_{i+1}$ ,  $P_{i+1}$  è in attesa di una risorsa acquisita da  $P_{i+2}, ... P_k$  è in attesa di una risorsa acquisita da  $P_i$ .

Le prime tre condizioni sono necessarie ma non sufficienti affinché si verifichi lo stallo. La quarta condizione diventa sufficiente solo nel caso in cui che per ogni tipo di risorsa riusabile **esista solo una copia.**


- L'esempio in figura mostra un caso in cui esistono 2 unità della risorsa R1. Il percorso circolare P1-R1-P2-R2 non porta ad una situazione di stallo in quanto il processo P3, dopo aver usato una copia di R1, la può rilasciare e quindi potrà essere allocata al processo P1, eliminando il percorso circolare.



- Questo secondo esempio mostra un caso in cui c'è solo un'unità della risorsa R1. In questo caso il percorso circolare P1-R1-P2-R2 porta ad una situazione di stallo in quanto P1 e P3 sono bloccati in attesa di R1 e P2 è bloccato in attesa di R2.



- In questo terzo caso non è presente un percorso circolare P1-R1-P2-R2 e il sistema non si trova in stallo.
- Tuttavia se successivamente, nel momento in cui P3 libera la risorsa R1 e questa venisse allocata a P2, si formerebbe un percorso circolare P1-R1-P2-R2 e quindi il sistema andrebbe in stallo. Se invece R1 venisse allocata a P1 non si verificherebbe una situazione di stallo.



# Metodi per il trattamento del blocco critico

- Il problema del blocco critico si può risolvere adottando tecniche di prevenzione:
  - **prevenzione statica**
  - **prevenzione dinamica**

## Prevenzione statica

- Consiste nello **scrivere adeguatamente i programmi**, in modo tale che almeno una delle quattro condizioni necessarie non si verifichi. Non considerando la condizione di mutua esclusione, che è fondamentale per l'uso delle risorse riusabili, si può intervenire sulle restanti tre condizioni: **possesso e attesa, mancanza di pre-rilascio, attesa circolare.**
- Le tecniche di prevenzione statica sono basate su vincoli sull'acquisizione delle risorse, che possono provocare un uso non efficiente delle risorse ed un rallentamento dei processi.

# Prevenzione dinamica

- Le tecniche di prevenzione dinamica si basano su algoritmi in grado di verificare, in base allo stato corrente di allocazione delle risorse e alle richieste dei processi, se l'assegnazione di risorse dovute ad una nuova richiesta da parte di un processo può portare a una situazione di stallo.
- Un noto algoritmo di prevenzione dinamica, ideato da Dijkstra, è l'**algoritmo del banchiere** (per una certa analogia al comportamento del banchiere) .
- L'algoritmo risulta molto riduttivo per essere usato nei SO di uso generale in quanto è basato sui seguenti vincoli:
  1. il sistema operativo può gestire un numero fisso di processi e un numero fisso di risorse. Inoltre i processi devono dichiarare inizialmente il numero massimo di risorse di cui hanno bisogno durante la loro esecuzione.
  2. I processi possono richiedere nuove risorse mantenendo le unità già in loro possesso.
  3. Tutte le risorse assegnate a un processo sono rilasciate quando il processo termina la sua esecuzione.

- Lo stato del sistema si dice **sicuro** se è possibile trovare una sequenza  **$P_h - P_j \dots P_k$**  con cui assegnare le risorse ai processi, detta **sequenza sicura**, in modo tale che tutti i processi possano usare le risorse che richiedono e terminare.
- Se, in un determinato istante, le risorse che un processo  **$P_i$**  richiede non sono disponibili, allora  **$P_i$**  si blocca fino a che tutti i processi che lo precedono nella sequenza liberino un numero sufficiente di risorse necessarie a  **$P_i$** .
- Se non esiste una sequenza sicura allora lo stato del sistema è detto **non è sicuro**. Uno stato non sicuro può portare a una condizione di blocco critico.
- L'algoritmo deve quindi consentire l'allocazione delle risorse ai processi solo quando le allocazioni portano a stati sicuri.

- Consideriamo, ad esempio, il caso di un sistema con tre processi P1, P2, P3 in cui siano disponibili 15 unità di un solo tipo di risorsa e che sia noto il massimo numero di risorse che ciascun processo può richiedere: 12 per P1, 3 per P2 e 11 per P3. Lo **stato iniziale** del sistema può essere così rappresentato:

	R1
P1	0
P2	0
P3	0

Risorse allocate

	R1
P1	12
P2	3
P3	11

Risorse richieste

R1
15

Risorse totali

R1
15

Risorse libere



- Se dopo un certo periodo di tempo sono state assegnate 8 unità a p1, 2 a p2 e 11 a P3, lo stato in cui il sistema si trova può essere così descritto:

	R1
P1	8
P2	2
P3	3

Risorse allocate

	R1
P1	4
P2	1
P3	8

Risorse richieste

R1
15

Risorse totali

R1
2

Risorse libere

- Vediamo se questo **stato è sicuro**, verificando se, a partire da questo stato, esiste una sequenza sicura.

	R1
P1	8
P2	2
P3	3

Risorse allocate

	R1
P1	4
P2	1
P3	8

Risorse richieste

R1
15

Risorse totali

R1
2

Risorse libere

- Si può notare che:
  1. il processo **P2** può allocare la risorsa richiesta, potendo quindi completare la sua esecuzione e liberare le sue 3 risorse che aveva allocato, portando quindi a 4 le risorse disponibili.

	R1
P1	8
<b>P2</b>	<b>3</b>
P3	3

Risorse allocate

	R1
P1	4
<b>P2</b>	<b>0</b>
P3	8

Risorse richieste

R1
15

Risorse totali

R1
1

Risorse libere

- Quindi quando P2 termina la stato di allocazione è il seguente:

	R1
P1	8
P2	0
P3	3

Risorse allocate

	R1
P1	4
P2	0
P3	8

Risorse richieste

R1
15

Risorse totali

R1
4

Risorse libere

- A questo punto, il processo **P1** può ora ottenere tutte le 4 risorse ancora necessarie e terminare, portando a 12 le risorse disponibili che consentono al processo **P3** di terminare.
- Lo stato indicato è quindi uno **stato sicuro** in quanto partendo da esso esiste la **sequenza sicura (P2, P1, P3)**.

- Altre sequenze potrebbero far passare il sistema da uno stato sicuro a uno stato non sicuro.

	R1
P1	8
P2	2
P3	3

Risorse allocate

	R1
P1	4
P2	1
P3	8

Risorse richieste

R1
15

Risorse totali

R1
2

Risorse libere

- Se, ad esempio, il processo **P3** chiede e ottiene una risorsa, il sistema in questo caso passerebbe in **uno stato che non è sicuro**.

	R1
P1	8
P2	2
<b>P3</b>	<b>4</b>

Risorse allocate

	R1
P1	4
P2	1
<b>P3</b>	<b>7</b>

Risorse richieste

R1
15

Risorse totali

R1
1

Risorse libere

- Infatti, l'unica risorsa rimasta libera può soddisfare soltanto la richiesta del processo P2 consentendogli di terminare l'esecuzione e liberare le 3 risorse in suo possesso.

	R1
P1	8
<b>P2</b>	<b>3</b>
P3	4

Risorse allocate

	R1
P1	4
<b>P2</b>	<b>0</b>
P3	7

Risorse richieste

R1
15

Risorse totali

R1
0

Risorse libere

- A questo punto nessun altro processo può terminare: P1 non può ottenere le 4 risorse di cui ha bisogno non essendo queste disponibili e quindi deve essere sospeso; analogamente P3 non può ottenere le 7 risorse e quindi anche esso viene sospeso. Si giunge quindi ad una **situazione di stallo**.

Nell'esempio, per evitare lo stallo, a partire dal precedente stato sicuro, la risorsa richiesta da P3 non deve essere ad esso allocata anche se disponibile.

# Rilevamento dei blocchi critici

- Se non si prendono adeguati provvedimenti di prevenzione statica o dinamica è possibile che si verifichino situazioni di stallo, coinvolgendo un certo numero di processi e di risorse.
- Spesso si ricorre solo alla rilevazione e alla eliminazione del blocco critico, senza ricorrere ad alcuna tecnica di prevenzione, come nel caso di Windows e Unix.
- L'algoritmo di **rilevazione** viene eseguito dal SO periodicamente con una frequenza che dipende dal tipo di applicazioni o quando ad esempio il grado d'uso della CPU scende sotto una certa soglia in quanto una condizione di blocco critico può rendere inefficienti le prestazioni del sistema.
- L'eliminazione del blocco critico si può ottenere con differenti tecniche, la più semplice ed estrema consiste nel fare terminare tutti i processi coinvolti.

- Una soluzione meno drastica consiste nel far terminare uno alla volta i processi coinvolti e liberando via via le risorse da esso allocate, fino a giungere all'eliminazione dello stallo. In questo caso è possibile usare politiche di selezione dei processi da far terminare, basate ad esempio sulla priorità, sul tempo di cpu utilizzato, sul numero di risorse allocate, etc.
- L'implementazione di tali strategie può portare ad un alto overhead per il SO, in quanto dopo ogni terminazione forzata occorre verificare di nuovo se c'è ancora una situazione di stallo.