

Applicazioni alla traduzione e compilazione

Corso di Fondamenti di Informatica - 1 modulo
Corso di Laurea in Informatica
Università di Roma "Tor Vergata"

Giorgio Gambosi

a.a. 2018-2019

1. Analisi lessicale. La sequenza di caratteri viene suddivisa in *token*, elementi significanti (come simboli terminali) nella definizione della sintassi del linguaggio. Costruzione della *tabella dei simboli*
2. Analisi sintattica. La sequenza di terminali viene esaminata per derivare la struttura sintattica del programma (albero sintattico, derivazione destra, derivazione sinistra)
3. Generazione del codice intermedio. A partire dalla struttura sintattica del programma e dalla tabella dei simboli, viene generata una prima versione tradotta del programma, in un linguaggio intermedio. Vengono effettuati una serie di controlli su aspetti non context-free del codice, come ad esempio il *type checking*.
4. Generazione codice finale e ottimizzazione.

Le prime due fasi sono basate sulla teoria dei linguaggi e degli automi.

- Analisi lessicale. Basata sui linguaggi di tipo 3: la struttura dei vari tipi di token è definita mediante espressioni regolari. Idealmente, l'analisi è effettuata esaminando la sequenza di caratteri per mezzo di tanti ASFD quanti sono i tipi di token.
- Analisi sintattica. Basata sui linguaggi context free: la struttura del linguaggio è definita mediante una grammatica CF. L'analisi è effettuata applicando un opportuno automa a pila per decidere la correttezza del programma (derivabilità nella grammatica del linguaggio) e, in tal caso, il corrispondente albero sintattico (o derivazione destra, o derivazione sinistra).

Basata sulla definizione di un insieme di *pattern*, mediante espressioni regolari. Ad esempio $[a - z, A - Z][a - z, A - Z, 0 - 9, .]^*$ può corrispondere alla struttura di un identificatore alfanumerico nel linguaggio, *for* alla parola chiave **for**

Un *lessema* è sequenza di caratteri che corrisponde a un pattern. Ad esempio 'a0_z' o 'my_counter' per il primo caso, o 'for' per il secondo

L'analizzatore lessicale associa un token (associato al pattern) ad ogni lessema: la sequenza di caratteri viene sostituita da una sequenza di token

pattern	token
$[a - z, A - Z][a - z, A - Z, 0 - 9, _, \cdot]^*$	id
$0 + [1 - 9][0 - 9]^*$	digit
$==, <, <=, >, >=$	rel_op
$=$	assign
<i>for</i>	for
<i>if</i>	if
<i>else</i>	else

if a0 > my_counter i=3 else j=0

if id rel_op id assign digit else id assign digit

L'analizzatore lessicale costruisce una tabella dei simboli incontrati, che associa ad ogni token (almeno quelli per i quali è necessario) il corrispondente lessema, insieme eventualmente ad altre informazioni (ad es. il tipo)

L'analisi sintattica fa riferimento ai soli token, mentre la generazione del codice successiva utilizza valori derivati dai lessemi.

- Simula un ASF per ogni espressione regolare definita (corrispondente a un pattern e un token)
- Quando un ASF accetta la stringa letta fino ad ora, restituisce il token corrispondente

Dato un insieme di espressioni regolari, è possibile derivare in modo automatico l'insieme di ASF che le accettano, e quindi l'analizzatore lessicale corrispondente: *Generatori di analizzatori lessicali*

Analizzatore sintattico, o *parser*:

- è associato ad una grammatica context free non ambigua, che definisce la struttura sintattica del linguaggio utilizzato
- riceve in input una stringa di token (simboli terminali della grammatica)
- verifica se la stringa è derivabile nella grammatica
- in tal caso, restituisce l'unico albero sintattico associato alla stringa

Un parser opera esaminando la stringa da sinistra a destra, in due possibili modi

- in funzione dei primi simboli letti, predice quale è la prossima produzione utilizzata in una derivazione sinistra della stringa, se esiste; l'albero sintattico viene prodotto dall'alto verso il basso (*parsing predittivo* o *top-down*)
- in funzione dei primi simboli letti, predice quale produzione è stata utilizzata per produrli, sostituendoli nella stringa con la parte sinistra della produzione: iterando questa operazione, si produce, se esiste, la produzione destra che genera la stringa, al contrario; l'albero sintattico viene prodotto dal basso verso l'alto (*bottom-up parsing*)

Predizioni non guidate in nessun modo delle produzioni utilizzate ad ogni passo (e quindi delle derivazioni) equivalgono alla simulazione di un NPDA, e comportano tempi di parsing esponenziali nella lunghezza della stringa.

E' necessario prevedere strutture particolari delle grammatiche CF utilizzate, che consentano di utilizzare parser che operano in modo più efficiente, guidati al meglio dai simboli letti

In una derivazione sinistra di una stringa, una forma di frase è necessariamente del tipo $V_T^+(V_T \cup V_N)^*$.

Esempio: la grammatica

$$\begin{aligned}T &\longrightarrow R \mid aTc \\ R &\longrightarrow RbR \mid \varepsilon\end{aligned}$$

e la produzione sinistra

$$\begin{aligned}T &\Longrightarrow \underline{a}Tc \Longrightarrow \underline{aa}Tcc \Longrightarrow \underline{aa}Rcc \Longrightarrow \underline{aa}RbRcc \Longrightarrow \underline{aa}RbRbRcc \Longrightarrow \\ &\underline{aab}RbRcc \Longrightarrow \underline{aab}RbRbRcc \Longrightarrow \underline{aabb}RbRcc \Longrightarrow \underline{aabbb}Rcc \Longrightarrow \underline{aabbbcc}\end{aligned}$$

Nel corso di un parsing predittivo, alla forma di frase xAw , con $x \in V_T^*$, $A \in V_N$, $w \in (V_T \cup V_N)^+$, corrisponde una situazione in cui il parser ha letto il prefisso x della stringa e deve determinare, sulla base di esso, quale delle produzioni aventi A a sinistra applicare.

Se la produzione selezionata è $A \rightarrow yBu$, con $y \in V_T^*$, $B \in V_N$, $u \in (V_T \cup V_N)^+$, la nuova forma di frase è $xyBuw$ e il parser, letta y , deve decidere quale produzione applicare per riscrivere B .

Il parser inizia da $\varepsilon S \sigma$, se σ è la stringa in input e S l'assioma.

letta	forma di frase	stringa	operazione
ε	<u>I</u>	<u>a</u> abbbcc	$T \longrightarrow aTc$
a	a <u>I</u> c	<u>a</u> bbbcc	$T \longrightarrow aTc$
aa	aa <u>I</u> cc	<u>b</u> bbcc	$T \longrightarrow R$
aa	aa <u>R</u> cc	<u>b</u> bbcc	$R \longrightarrow RbR$
aa	aa <u>R</u> bRcc	<u>b</u> bbcc	$R \longrightarrow RbR$
aa	aa <u>R</u> bRbRcc	<u>b</u> bbcc	$R \longrightarrow \varepsilon$
aab	aab <u>R</u> bRcc	<u>b</u> bcc	-
aab	aab <u>R</u> bRcc	<u>b</u> bcc	$R \longrightarrow \varepsilon$
aabb	aabb <u>R</u> cc	<u>b</u> cc	-
aabb	aabbcc	<u>c</u> c	$R \longrightarrow \varepsilon$
aabbc	aabbcc	<u>c</u>	-
aabbcc	aabbcc	ε	-

Grammatica

$$\begin{aligned}E &\longrightarrow TE' \\E' &\longrightarrow +TE' \mid \varepsilon \\T &\longrightarrow FT' \\T' &\longrightarrow *FT' \mid \varepsilon \\F &\longrightarrow (E) \mid \mathbf{id}\end{aligned}$$

Stringa

`id+id*id`

ε	<u>E</u>	<u>id</u> +id*id	$E \longrightarrow TE'$
ε	<u>T</u> E'	<u>id</u> +id*id	$T \longrightarrow FT'$
ε	<u>F</u> T'E'	<u>id</u> +id*id	$F \longrightarrow \text{id}$
id	id <u>T</u> 'E'	<u>+</u> id*id	$T' \longrightarrow \varepsilon$
id	id <u>E</u> '	<u>+</u> id*id	$E' \longrightarrow +TE'$
id+	id+ <u>T</u> E'	<u>id</u> *id	$T \longrightarrow FT'$
id+	id+ <u>F</u> T'E'	<u>id</u> *id	$F \longrightarrow \text{id}$
id+id	id+id <u>T</u> 'E'	<u>*</u> id	$T' \longrightarrow *FT'$
id+id*	id+id* <u>F</u> T'E'	<u>id</u>	$F \longrightarrow \text{id}$
id+id*id	id+id*id <u>T</u> 'E'	ε	$T' \longrightarrow \varepsilon$
id+id*id	id+id*id <u>E</u> '	ε	$E' \longrightarrow \varepsilon$
id+id*id	id+id*id	ε	-

Ad ogni passo è possibile selezionare una sola produzione, guardando un solo terminale (token): $LL(1)$

Implementazione di parser top down: una funzione $A()$ per ogni $A \in V_N$, con la struttura seguente. Il programma inizia da $S()$

$A()$:

for each $A \rightarrow X_1 X_2 \cdots X_k \in P$:

for i in range($1, k + 1$):

if $X_i \in V_N$:

if $X_i()$:

return 1

elif X_i uguale al prossimo simbolo a della stringa:

avanza al simbolo successivo

else :

break

return 0

Utilizzo del *backtracking*: può essere molto inefficiente

Backtracking: esplorazione ricorsiva di tutte le possibilità.

La scelta della produzione da considerare può essere guidata dall'esame dei caratteri successivi.

La grammatica non può essere *ricorsiva sinistra*

$$A \longrightarrow Aw$$

Se per ogni simbolo non terminale da espandere i prossimi k caratteri della stringa consente di individuare la produzione da applicare, il parser è $LL(k)$

- Left-to-right: la derivazione è calcolata da sinistra a destra (dalla prima produzione applicata all'ultima)
- Leftmost derivation: la derivazione calcolata è sinistra
- k simboli (di *look-ahead*) da considerare

Un linguaggio CF è $LL(k)$ se esiste un parser $LL(k)$ che può effettuare l'analisi sintattica

Consideriamo il caso $LL(1)$, per semplicità.

Per ogni sequenza $\alpha \in (V_T \cup V_N)^+$, $c \in V_T$, diciamo che $c \in \text{FIRST}(\alpha)$ se e solo se $\alpha \xRightarrow{*} c\beta$ per $\beta \in (V_T \cup V_N)^*$

Quindi $\text{FIRST}(\alpha)$ è l'insieme dei terminali che possono comparire in prima posizione in forme di frase derivate a partire da α

Siamo in particolare interessati a $\text{FIRST}(\alpha)$ se α è la parte destra di una produzione $A \rightarrow \alpha$: perché?

Perché se $c \in \text{FIRST}(\alpha)$ e $A \rightarrow \alpha$, una stringa $w = cy$ che inizia per c potrebbe essere derivata a partire da A , in quanto $A \Rightarrow \alpha \xRightarrow{*} c\beta$

Date le A -produzioni in P

$$A \longrightarrow \alpha_1 \mid \alpha_2 \mid \cdots \mid \alpha_k$$

se ogni terminale appartiene a non più di un insieme $\text{FIRST}(\alpha_i)$, allora possiamo sempre individuare quale produzione applicare per riscrivere A , esaminando il solo prossimo carattere c

Infatti, va applicata $A \longrightarrow \alpha_i$ se e solo se $c \in \text{FIRST}(\alpha_i)$

Se non esiste α_i tale che $c \in \text{FIRST}(\alpha_i)$, c'è un errore e la parte di stringa da leggere non è derivabile a partire da A

Per la costruzione di $\text{FIRST}(\alpha)$ va utilizzato il predicato $\text{Nullable}(\beta)$ definito come $\text{Nullable}(\beta) = \text{TRUE}$ se e solo se β è *annullabile*, cioè se e solo se esiste una derivazione $\beta \xRightarrow{*} \varepsilon$. Una produzione $B \rightarrow \beta$ è *annullabile* se e solo se β è annullabile.

La costruzione di $\text{Nullable}(\beta)$ è basata sulle seguenti proprietà

$$\text{Nullable}(\varepsilon) = \text{TRUE}$$

$$\text{Nullable}(a) = \text{False} \quad \forall a \in V_T$$

$$\text{Nullable}(\alpha\beta) = \text{Nullable}(\alpha) \wedge \text{Nullable}(\beta)$$

$$\text{Nullable}(A) = \bigvee_i \text{Nullable}(\alpha_i) \quad \forall A \in V_N, \forall A \rightarrow \alpha_i \in P$$

La costruzione di $\text{FIRST}(\alpha)$ avviene in modo simile.

Consideriamo in primo luogo la costruzione di $\text{FIRST}(X)$, dove X è un simbolo della grammatica, $X \in V_T \cup V_N$

1. Se $X \in V_T$, allora $\text{FIRST}(X) = \{X\}$
2. Se $X \in V_N$, per ogni $X \rightarrow Y_1 Y_2 \cdots Y_k \in P$ ($k \geq 1$):
 - 2.1 $\text{FIRST}(Y_1) \subseteq \text{FIRST}(X)$
 - 2.2 Per $i = 2, \dots, k$, se $\text{Nullable}(Y_1 \cdots Y_{i-1})$ allora $\text{FIRST}(Y_i) \subseteq \text{FIRST}(X)$

Costruzione di $\text{FIRST}(X_1 \cdots X_n)$ da $\text{FIRST}(X)$ per ogni X :

- $\text{FIRST}(X_1) \subseteq \text{FIRST}(X_1 \cdots X_n)$
- Per $i = 2, \dots, n$, se $\text{Nullable}(X_1 \cdots X_{i-1})$ allora $\text{FIRST}(X_i) \subseteq \text{FIRST}(X_1 \cdots X_n)$

Da quanto detto, se $x = cy$ è la stringa da leggere e A il terminale da riscrivere, le possibili produzioni da applicare sono tutte le $A \rightarrow \alpha_i$ tali che $c \in \text{FIRST}(\alpha_i)$. Se in tutti i casi possibili c'è al più una di tali produzioni, abbiamo un parser $LL(1)$.

Errore! In realtà cy potrebbe essere prodotta in modo diverso:

Supponiamo che la forma di frase attuale sia ABw , con $w \in (V_T \cup V_N)^*$ e supponiamo che A sia annullabile, e quindi che esista una derivazione $A \xRightarrow{*} \varepsilon$: allora, x potrebbe essere ancora derivabile se $c \in \text{FIRST}(B)$, e quindi $B \xRightarrow{*} c\beta$, in quanto

$$ABw \xRightarrow{*} Bw \xRightarrow{*} c\beta w$$

Dati $A \in V_N$ e $a \in V_T$, $a \in \text{FOLLOW}(A)$ se e solo se esiste una forma di frase derivata dall'assioma in cui a segue immediatamente A .

Quindi $a \in \text{FOLLOW}(A)$ se e solo se esistono $\alpha, \beta \in (V_T \cup V_N)^*$ tali che
 $S \xRightarrow{*} \alpha A a \beta$

Durante il parsing, se A è il non terminale da riscrivere e c il simbolo attualmente letto, la produzione $A \rightarrow \varepsilon$ (se esiste) può essere applicata nel caso in cui $c \in \text{FOLLOW}(A)$

Per tener conto del caso in cui A potrebbe essere l'ultimo simbolo di una forma di frase, cioè in cui $S \xRightarrow{*} \alpha A$, estendiamo la grammatica con:

- un non terminale $\$$ di fine stringa
- un nuovo assioma S'
- una produzione $S' \rightarrow S\$$

Evidentemente, A può comparire a fine stringa nella prima grammatica se e solo se $\$ \in \text{FOLLOW}(A)$ nella nuova grammatica.

FOLLOW viene costruita a partire da un insieme di vincoli derivati dalle produzioni.

- $\$ \in \text{FOLLOW}(S)$
- Se $A \rightarrow \alpha B \beta \in P$, allora $\text{FIRST}(\beta) \subseteq \text{FOLLOW}(B)$
- se $A \rightarrow \alpha B \beta \in P$ e $\text{Nullable}(\beta)$, allora $\text{FOLLOW}(A) \subseteq \text{FOLLOW}(B)$
- se $A \rightarrow \alpha B \in P$ allora $\text{FOLLOW}(A) \subseteq \text{FOLLOW}(B)$

Grammatica

$$\begin{array}{ll} E & \longrightarrow TE' \\ E' & \longrightarrow +TE' \mid \varepsilon \\ T & \longrightarrow FT' \\ T' & \longrightarrow *FT' \mid \varepsilon \\ F & \longrightarrow (E) \mid \text{id} \end{array}$$

$\text{Nullable}(E') = \text{Nullable}(T') = \text{TRUE}$

- $\text{FIRST}(F) = \{(\text{id})\}$
- $\text{FIRST}(T') = \{*\}$
- $\text{FIRST}(E') = \{+\}$
- $\text{FIRST}(T) = \text{FIRST}(F) = \{(\text{id})\}$
- $\text{FIRST}(E) = \text{FIRST}(T) = \{(\text{id})\}$

- $\$ \in \text{FOLLOW}(E)$
- $\text{FIRST}(E') = \{+\} \subseteq \text{FOLLOW}(T)$
- $\text{FIRST}(T') = \{*\} \subseteq \text{FOLLOW}(F)$
- $\text{FIRST}(')') = \{\}) \subseteq \text{FOLLOW}(E)$
- $\text{FOLLOW}(E) \subseteq \text{FOLLOW}(E')$
- $\text{FOLLOW}(E) \subseteq \text{FOLLOW}(T)$
- $\text{FOLLOW}(T) \subseteq \text{FOLLOW}(T')$
- $\text{FOLLOW}(E') \subseteq \text{FOLLOW}(T)$
- $\text{FOLLOW}(T') \subseteq \text{FOLLOW}(F)$

Da cui deriva

- $\text{FOLLOW}(E) = \{\$,)\}$
- $\text{FOLLOW}(E') = \text{FOLLOW}(E) = \{\$,)\}$
- $\text{FOLLOW}(T) = \text{FOLLOW}(E) \cup \{+\} = \{\$,), +\}$
- $\text{FOLLOW}(T') = \text{FOLLOW}(T) = \{\$,), +\}$
- $\text{FOLLOW}(F) = \text{FOLLOW}(T') \cup \{*\} = \{\$,), +, *\}$

Associa ad ogni coppia (a, X) , $a \in V_T$, $X \in V_N$, un insieme di produzioni (1 se $LL(1)$) da applicare nel caso in cui X sia il non terminale da riscrivere e a sia il simbolo letto in input.

Costruzione della tabella M :

Per ogni produzione $A \rightarrow \alpha \in P$:


- se $\alpha \neq \epsilon$, per ogni $a \in \text{FIRST}(A)$ aggiungi $A \rightarrow \alpha$ a $M[A, a]$
- se $\text{Nullable}(\alpha)$, per ogni $b \in \text{FOLLOW}(A)$ aggiungi $A \rightarrow \alpha$ a $M[A, b]$

Per la grammatica precedente

	id	+	*	()	\$
E	$E \rightarrow TE'$			$E \rightarrow TE'$		
E'		$E' \rightarrow +TE'$			$E' \rightarrow \varepsilon$	$E' \rightarrow \varepsilon$
T	$T \rightarrow FT'$			$T \rightarrow FT'$		
T'		$T' \rightarrow \varepsilon$	$T' \rightarrow *FT'$		$T' \rightarrow \varepsilon$	$T' \rightarrow \varepsilon$
F	$F \rightarrow \text{id}$			$F \rightarrow (E)$		

Parsing predittivo non ricorsivo

Utilizza uno stack (pila) in modo esplicito, invece che implicitamente, simulando una derivazione sinistra della stringa.



```
input.first()
stack.push(S$)
while stack.top()! = $:
    if stack.top() == input.current():
        stack.pop()
        input.next()
    elif table[stack.top(),input.current()]! = Null:
        Let table[stack.top(),input.current()] be  $X \rightarrow Y_1 \cdots Y_k$ 
        output stack.top()  $\rightarrow Y_1 \cdots Y_k$ 
        stack.pop()
        stack.push( $Y_1 \cdots Y_k$ )
    else:
        error
```

Parsing predittivo non ricorsivo

Esempio di parsing di $\text{id} + \text{id} * \text{id}$

Matched	Stack	Input	Action
	E\$	id+id*id\$	
	TE'\$	id+id*id\$	output $E \rightarrow TE'$
	FT'E'\$	id+id*id\$	output $T \rightarrow FT'$
	idT'E'\$	id+id*id\$	output $F \rightarrow \text{id}$
id	T'E'\$	+id*id\$	match id
id	E'\$	+id*id\$	output $T' \rightarrow \epsilon$
id	+TE'\$	+id*id\$	output $E' \rightarrow +TE'$
id+	TE'\$	id*id\$	match +
id+	FT'E'\$	id*id\$	output $T \rightarrow FT'$
id+	idT'E'\$	id*id\$	output $F \rightarrow \text{id}$
id+id	T'E'\$	*id\$	match id


Parsing predittivo non ricorsivo

Matched	Stack	Input	Action
id+id	*FT'E'\$	*id\$	output $T' \rightarrow *FT'$
id+id*	FT'E'\$	id\$	match *
id+id*	idT'E'\$	id\$	output $F \rightarrow id$
id+id*id	T'E'\$	\$	match id
id+id*id	E'\$	\$	output $T' \rightarrow \varepsilon$
id+id*id	\$	\$	output $E' \rightarrow \varepsilon$

Ne risulta la derivazione sinistra

$$\begin{array}{ll} E \Rightarrow TE' & \Rightarrow FT'E' \\ \Rightarrow \text{id}T'E' & \Rightarrow \text{id}E' \\ \Rightarrow \text{id} + TE' & \Rightarrow \text{id} + FT'E' \\ \Rightarrow \text{id} + \text{id}T'E' & \Rightarrow \text{id} + \text{id} * FT'E' \\ \Rightarrow \text{id} + \text{id} * \text{id}T'E' & \Rightarrow \text{id} + \text{id} * \text{id}E' \\ \Rightarrow \text{id} + \text{id} * \text{id} & \end{array}$$

E l'albero sintattico



Costruzione dell'albero sintattico dal basso verso l'alto.

Equivalentemente, costruzione della una derivazione destra (in ordine inverso rispetto alla derivazione stessa).

Parsing LR(k):

- Left-to-right: la derivazione è calcolata da sinistra a destra (dalla prima produzione applicata all'ultima)
- Rightmost derivation: la derivazione calcolata è destra
- k simboli (di *look-ahead*) da considerare

Operazioni base del parsing LR:

Una sottostringa (**handle**) della forma di frase attuale α , corrispondente alla parte destra di una produzione, viene sostituita dalla parte sinistra.

- Forma di frase attuale $\alpha = \delta\eta\zeta$, con $\delta, \zeta \in (V_T \cup V_N)^*$, e $\eta \in (V_T \cup V_N)^* V_N (V_T \cup V_N)^*$
- Produzione $A \longrightarrow \eta \in P$

Riduzione: la nuova forma di frase è $\delta A \zeta$

Consideriamo ancora la grammatica

$$\begin{aligned} E &\longrightarrow TE' \\ E' &\longrightarrow +TE' \mid \varepsilon \\ T &\longrightarrow FT' \\ T' &\longrightarrow *FT' \mid \varepsilon \\ F &\longrightarrow (E) \mid \text{id} \end{aligned}$$

e la stringa $\text{id} + \text{id} * \text{id}$.

Esempio di parsing bottom up

Assumiamo di poter individuare sempre la prima handle da sinistra nella forma di frase attuale.

Handle	Produzione	Result
id +id*id\$	$F \rightarrow \text{id}$	F+id*id
F+id*id\$	$T' \rightarrow \varepsilon$	FT'+id*id
FT' +id*id\$	$T \rightarrow FT'$	T+id*id
T+ id *id\$	$F \rightarrow \text{id}$	T+F*id
T+F* id \$	$F \rightarrow \text{id}$	T+F*F
T+F*F\$	$T' \rightarrow \varepsilon$	T+F*FT'
T+F* FT' \$	$T' \rightarrow *FT'$	T+FT'
T+ FT' \$	$T \rightarrow FT'$	T+T
T+T\$	$E' \rightarrow \varepsilon$	T+TE'
T+ TE' \$	$E' \rightarrow +TE'$	TE'
TE' \$	$E \rightarrow TE'$	E

La sequenza di produzioni individuate, lette al contrario (dal basso in alto), forniscono la derivazione destra della stringa

$$\begin{aligned} E &\Longrightarrow TE' \Longrightarrow T + TE' \Longrightarrow T + T \Longrightarrow T + FT' \Longrightarrow T + F * FT' \Longrightarrow \\ T + F * F &\Longrightarrow T + F * \text{id} \Longrightarrow T + \text{id} * \text{id} \Longrightarrow FT' + \text{id} * \text{id} \Longrightarrow \\ F + \text{id} * \text{id} &\Longrightarrow \text{id} + \text{id} * \text{id} \end{aligned}$$

Problema: come individuare handle e riduzione?

Parsing shift-reduce

Un parser **shift-reduce** effettua parsing bottom up utilizzando:

- una pila di simboli della grammatica
- un buffer di input, in cui è contenuta la parte dell'input ancora da leggere

Il carattere $\$ \notin V_T$ è utilizzato per marcare il fondo della pila e la fine della stringa di input, per cui inizialmente, se w è la stringa:

- la pila contiene $\$$
- il buffer contiene $w\$$

Pila
 $\$$

Input
 $w\$$

Parsing shift-reduce: operazioni

Reduce: i simboli in cima alla pila corrispondono ad una handle per una produzione $A \rightarrow \alpha$. Viene effettuata una reduce, passando da

Pila	Input		Pila	Input
$\$ \beta \alpha$	$w \$$	a	$\$ \beta A$	$w \$$

Shift: i simboli in cima alla pila non corrispondono ad una handle. Il prossimo simbolo in input viene posto sulla pila, passando da

Pila	Input		Pila	Input
$\$ \alpha$	$aw \$$	a	$\$ \alpha a$	$w \$$

Accept: la pila contiene $\$S$, dove S è l'assioma della grammatica, il buffer di input contiene $\$$ (la stringa è terminata). La stringa è accettata

Error: non ci sono altre azioni eseguibili nella configurazione attuale di pila e buffer. La stringa è rifiutata

Parsing shift-reduce

Pila	Input	Azione
\$	id+id*id\$	shift
\$id	+id*id\$	reduce $F \rightarrow id$
\$F	+id*id\$	reduce $T' \rightarrow \varepsilon$
\$FT'	+id*id\$	reduce $T \rightarrow FT'$
\$T	+id*id\$	shift
\$T+	id*id\$	shift
\$T+id	*id\$	reduce $F \rightarrow id$
\$T+F	*id\$	shift
\$T+F*	id\$	shift
\$T+F*id	\$	reduce $F \rightarrow id$
\$T+F*F	\$	reduce $T' \rightarrow \varepsilon$
\$T+F*FT'	\$	reduce $T' \rightarrow *FT'$

Parsing shift-reduce

Pila	Input	Azione
$\$T + \textcolor{red}{FT}'$	\$	reduce $T \longrightarrow FT'$
$\$T + T$	\$	reduce $E' \longrightarrow \varepsilon$
$\$T + \textcolor{red}{TE}'$	\$	reduce $E' \longrightarrow +TE'$
$\textcolor{red}{\$TE}'$	\$	reduce $E \longrightarrow TE'$
$\textcolor{red}{\$E}$	\$	accept

Parsing shift-reduce

Pila	Input	Azione
$\$T + \textcolor{red}{FT}'$	\$	reduce $T \rightarrow FT'$
$\$T + T$	\$	reduce $E' \rightarrow \varepsilon$
$\$T + \textcolor{red}{TE}'$	\$	reduce $E' \rightarrow +TE'$
$\textcolor{red}{TE}'$	\$	reduce $E \rightarrow TE'$
$\textcolor{red}{E}$	\$	accept

Si può mostrare che l'handle, in un parsing bottom up, apparirà sempre in cima alla pila. Due casi possibili.

Derivazione destra:

$$S \xRightarrow{*} \alpha Az \Longrightarrow \alpha \beta B y z \Longrightarrow \alpha \beta \gamma y z$$

dove si sono applicate le produzioni $A \longrightarrow \beta B y$ e $B \longrightarrow \gamma y$, con $\alpha, \beta, \gamma \in (V_T \cup V_N)^*$ e $y, z \in V_T^*$

Nel parsing, si ha la corrispondente sequenza di azioni

Pila	Input	Azione
$\$ \alpha \beta \gamma$	$yz \$$	reduce $B \longrightarrow \gamma$
$\$ \alpha \beta B$	$z \$$	shift y
$\$ \alpha \beta B y$	$z \$$	reduce $A \longrightarrow \beta y$
$\$ \alpha A$	$z \$$	

Derivazione destra:

$$S \xRightarrow{*} \alpha B x A z \Longrightarrow \alpha B x y z \Longrightarrow \alpha \gamma x y z$$

dove si sono applicate le produzioni $A \longrightarrow y$ e $B \longrightarrow \gamma y$, con $\alpha, \gamma \in (V_T \cup V_N)^*$ e $x, y, z \in V_T^*$

Nel parsing, si ha la corrispondente sequenza di azioni

Pila	Input	Azione
$\$ \alpha \gamma$	$xyz\$$	reduce $B \longrightarrow \gamma$
$\$ \alpha B$	$xyz\$$	shift xy
$\$ \alpha B x y$	$z\$$	reduce $A \longrightarrow y$
$\$ \alpha B x A$	$z\$$	